BÁO CÁO THỰC HÀNH

BÀI TẬP 1: THỰC HÀNH DATA WRANGLING VỚI PYTHON/PANDAS

1. Trình tự thực hiện:

- **Bước 1 - Tải dữ liệu:**

Truy cập kaggle.com/datasets → tìm bộ dữ liệu phim có tệp movies.csv → Download → giải nén và lưu movies.csv.

Cần xử lý "Science Fiction" thành "Science_Fiction" để loại bỏ khoảng trắng, phân tách thành từng cá thể riêng biệt: "Action", "Adventure", "Fantasy" và "Science_Fiction" tiếp đến loại bỏ ký tự "_" để thành "Science Fiction"

- **Bước 2 - Mở Colab:**

Truy cập colab.research.google.com → New notebook → tải movies.csv lên mục Files/drive/MyDrive (hoặc dùng files.upload()).

- **Bước 3 - Làm sạch:**

Đọc CSV bằng pandas; chuẩn hóa release_date thành dạng YYYY-MM-DD; chuyển budget, revenue sang số; thay giá trị thiếu, âm hoặc vô nghĩa bằng 0; bỏ dòng thiếu tên phim.

- **Bước 4 - Tạo cột và xuất tệp:**

Tính TOTAL_FINANCE = budget + revenue; lưu thành movies_clean.csv và tải xuống máy.

2. Lệnh Python thực hiện trên Google Colab

Prompt tạo lệnh Python:

> *Bạn là chuyên gia phân tích dữ liệu Python. Hãy viết code chạy trên Google Colab để làm sạch tệp movies.csv tại /content/drive/MyDrive/movies.csv bằng Pandas.*
>
> *Yêu cầu:*
>
> *Loại bỏ dòng trùng lặp, giá trị thiếu và vô nghĩa.*
>
> *Chuẩn hóa định dạng ngày thành YYYY-MM-DD.*
>
> *Bổ sung thêm cột tính tổng phù hợp với dữ liệu*
>
> *Lưu ý: Code ngắn gọn, có chú thích tiếng Việt, kiểm tra cột trước khi xử lý và chạy trực tiếp trên Google Colab.*

Mã lệnh Python:

```python
import pandas as pd

# 1. Nạp dữ liệu gốc từ Drive
df = pd.read_csv('/content/drive/MyDrive/movies.csv')

# 2. Loại bỏ các dòng trùng lặp và các giá trị bị thiếu (nếu cần)
df_clean = df.drop_duplicates().copy()

# Loại bỏ các giá trị vô nghĩa (ví dụ: budget hoặc revenue nhỏ hơn hoặc bằng 0)
df_clean = df_clean[(df_clean['budget'] > 0) & (df_clean['revenue'] > 0)]

# 3. Định dạng lại cột ngày tháng về kiểu YYYY-MM-DD
if 'release_date' in df_clean.columns:
    df_clean['release_date'] = pd.to_datetime(df_clean['release_date'], errors='coerce').dt.strftime('%Y-%m-%d')

# 4. Xuất file movies_clean.csv trực tiếp vào thư mục MyDrive trên Google Drive
df_clean.to_csv('/content/drive/MyDrive/movies_clean.csv', index=False)
print("Đã lưu tệp movies_clean.csv thành công vào Google Drive của bạn!")
```

Bảng minh họa kết quả xử lý

Trường dữ liệu	Trước xử lý	Sau xử lý	Ý nghĩa
release_date	03/15/2020	2020-03-15	Chuẩn hóa ngày
budget	NaN / -100	0	Loại giá trị lỗi
revenue	250000	250000	Giữ giá trị (Số) hợp lệ
TOTAL_FINANCE	(Chưa có)	250000	budget + revenue

Kết quả: Tệp movies_clean.csv có định dạng ngày thống nhất, dữ liệu tài chính hợp lệ và cột tổng mới, sẵn sàng cho phân tích.

BÀI TẬP 2: XÂY DỰNG PIPELINE ETL ĐƠN GIẢN

1. Tổng quan về Pipeline ETL trên Google Colab

Pipeline ETL (Extract - Transform - Load) được thực thi trực tiếp trên môi trường điện toán đám mây **Google Colab Notebooks**. Việc áp dụng công cụ này giúp loại bỏ yêu cầu cài đặt môi trường phức tạp trên máy cục bộ, đồng thời tận dụng khả năng chia sẻ và chạy mã nguồn linh hoạt trên nền tảng đám mây. Sơ đồ quy trình:

[Google Drive / CSV Raw] ⟶ [Colab Python ETL: Transform] ⟶ [SQLite DB & CSV Output]

2. Chi tiết các giai đoạn trong Pipeline & Quy trình chuẩn hóa

- **Extract (Trích xuất):** Tải dữ liệu từ Google Drive hoặc nạp trực tiếp file input_data.csv vào môi trường Google Colab Notebooks bằng hàm pd.read_csv().
- **Transform (Quy trình chuẩn hóa 4 bước):** Dữ liệu thô trải qua quy trình 4 bước chuẩn hóa dữ liệu nghiêm ngặt:

  Bước 1: Xử lý dữ liệu khuyết thiếu: Kiểm tra ô trống (null/NaN) bằng .isnull() và loại bỏ hoặc thay thế phù hợp.

Bước 2: Chuẩn hóa Tên (full_name): Xóa khoảng trắng thừa 2 đầu/giữa (.strip()) và định dạng chữ cái đầu viết hoa (.title()).
Bước 3: Chuẩn hóa Email (email): Đưa toàn bộ chuỗi về chữ thường (.lower()) và xóa sạch khoảng trắng vô tình nhập vào.
Bước 4: Chuẩn hóa Số điện thoại (phone): Áp dụng biểu thức chính quy Regex (r'\D') để loại bỏ khoảng trắng, dấu chấm, gạch nối, đưa về định dạng số chuẩn.

- **Load (Nạp dữ liệu):** Ghi dữ liệu đã làm sạch vào bảng cleaned_users trong cơ sở dữ liệu SQLite (database.db) và tải bản sao CSV (output_cleaned.csv) về máy từ Colab.

3. Prompt Mẫu Để Tạo Lệnh Chuẩn Hóa Trên Colab

Dưới đây là Prompt mẫu dùng để yêu cầu AI tạo mã Python chuẩn hóa chạy trên Google Colab Notebooks:

Prompt:

Viết giúp tôi script Python chạy trên Google Colab Notebooks thực hiện pipeline ETL làm sạch dữ liệu từ CSV:
Đọc file CSV 'input_data.csv' gồm các cột [id, full_name, email, phone].
Chuẩn hóa các nội dung sau:
full_name: Loại bỏ khoảng trắng dư thừa và định dạng chữ cái đầu viết hoa
email: Xóa khoảng trắng và chuyển toàn bộ thành chữ thường
phone: loại bỏ mọi ký tự không phải số
Xuất file output_data_cleaned.csv vào Files/content/drive/MyDrive

Mã lệnh Python:

```python
import sqlite3
import pandas as pd

def extract(file_path: str) -> pd.DataFrame:
    """1. EXTRACT: Đọc dữ liệu từ file CSV thô."""
    print("[+] Đang đọc dữ liệu thô...")
    df = pd.read_csv(file_path)
    return df

def transform(df: pd.DataFrame) -> pd.DataFrame:
    """2. TRANSFORM: Làm sạch và chuẩn hóa các cột."""
    print("[+] Đang chuẩn hóa dữ liệu...")

    # 2.1 Cột full_name: Loại bỏ khoảng trắng thừa + Viết hoa chữ cái đầu mỗi từ
    df['full_name'] = df['full_name'].astype(str).str.strip().str.title()

    # 2.2 Cột email: Xóa khoảng trắng + Chuyển toàn bộ về chữ thường
    df['email'] = df['email'].astype(str).str.strip().str.lower()

    # 2.3 Cột phone: Xóa ký tự không phải số (khoảng trắng, dấu chấm)
    df['phone'] = df['phone'].astype(str).str.replace(r'\D', '', regex=True)

    return df

def load(df: pd.DataFrame, db_name: str, csv_out: str):
    """3. LOAD: Ghi dữ liệu vào Database SQLite và lưu bản sao CSV."""
    print("[+] Đang ghi dữ liệu vào SQLite và CSV mới...")

    # Ghi vào SQLite Database
    conn = sqlite3.connect(db_name)
    df.to_sql('cleaned_users', conn, if_exists='replace', index=False)
    conn.close()

    # Ghi ra file CSV đã làm sạch
    df.to_csv(csv_out, index=False)
    print("[✓] Đã hoàn thành Pipeline thành công!")

if __name__ == '__main__':
    # Chạy quy trình ETL
    data_raw = extract('/content/drive/MyDrive/input_data.csv')
    data_clean = transform(data_raw)
    load(data_clean, db_name='database.db', csv_out='output_data_cleaned.csv')
```

Kết quả sau khi xử lý:

id	full_name	email	phone
1	Nguyen Van A	nva@gmail.com	0901234567
2	Tran Thi B	ttb@yahoo.com	0912345678
3	Le Van C	lvc@gmail.com	0923456789

Show 10 per page

4. Đánh Giá: Google Colab ETL vs Excel / Google Sheets

Tiêu chí đánh giá	Excel / Google Sheets	Google Colab & Python ETL
Môi trường làm việc	Cài đặt phần mềm cục bộ, phụ thuộc vào cấu hình máy tính cá nhân.	Chạy trên đám mây (Google Cloud), không cần cài đặt, dễ dàng chia sẻ qua đường link.
Tính tự động hóa	Phải thao tác chuẩn hóa thủ công từng bước hoặc viết	Tự động hóa hoàn toàn bằng đoạn mã script Python, chạy lại

	Macro phức tạp.	toàn bộ chỉ bằng 1 nút bấm.
Khả năng mở rộng	Giới hạn số dòng/ô, dễ bị đơ/treo máy khi xử lý file dung lượng lớn.	Xử lý hàng triệu dòng dữ liệu mượt mà nhờ phần cứng Cloud mạnh mẽ của Google Colab.
Tích hợp & Kiểm soát	Khó theo dõi lịch sử chỉnh sửa, dễ bị ghi đè dữ liệu gây sai sót.	Dễ tích hợp lưu trữ trên Google Drive, kết nối SQLite, BigQuery và quản lý mã nguồn bằng Git.

5. Kết Luận

Sử dụng Google Colab Notebooks kết hợp Python để thực hiện Pipeline ETL giúp tự động hóa và chuẩn hóa dữ liệu một cách nhất quán, chính xác. Mô hình này khắc phục hoàn toàn hạn chế của các công cụ bảng tính thủ công, đảm bảo khả năng mở rộng cho các bài toán xử lý dữ liệu quy mô lớn.